Фреймворк РуТогсh для разработки искусственных нейронных сетей

Урок 3. Dataset, Dataloader, BatchNorm, Dropout, Оптимизация

Практическое задание

→ Попрактикуемся с тем, что изучили

Будем практиковаться на датасете: https://www.kaggle.com/c/avito-demand-prediction

Ваша задача:

- 1. Создать Dataset для загрузки данных (используем только числовые данные)
- 2. Обернуть его в Dataloader
- 3. Написать архитектуру сети, которая предсказывает число показов на основании числовых данных (вы всегда можете нагенерить дополнительных факторов). Сеть должна включать BatchNorm слои и Dropout (или НЕ включать, но нужно обосновать)
- 4. Учить будем на функцию потерь с кагла (log RMSE) нужно её реализовать
- 5. Сравните сходимость Adam, RMSProp и SGD, сделайте вывод по качеству работы модели

train-test разделение нужно сделать с помощью sklearn random_state=13, test_size = 0.25

Вопросы? в личку @Kinetikm

Выполнил Соковнин ИЛ

▼ Как загрузить данные на Colaboratory

https://www.youtube.com/watch?v=Ve5oW1qqbZg https://colab.research.google.com/drive/1e3bbNmpQ1Wremp4O5NiNOgqTV-_WG5wL#scrollTo=1_lwnzf4Bhlu

■ Шаг 0. Подготовка данных

Загружаем данные с Google Drive, затем распаковываем их в папку /content/drive/my_drive/data

```
!ls -la

total 16
drwxr-xr-x 1 root root 4096 Mar 23 14:22 .
drwxr-xr-x 1 root root 4096 Mar 30 08:53 ..
drwxr-xr-x 4 root root 4096 Mar 23 14:21 .config
drwxr-xr-x 1 root root 4096 Mar 23 14:22 sample_data

Создаём дирректорию для данных

!mkdir -p /content/drive/my_drive/data
```

▼ Использование Google Drive

Копирование больших файлов просходит значительно быстрее, если использовать Google Drive.

Подключение Google Drive к виртуальной машине:

```
from google.colab import drive
drive.mount('/content/gdrive', force_remount=True)
    Mounted at /content/gdrive
!ls /content/gdrive/"My Drive" -la
```

```
total 2332713
        drwx----- 2 root root 4096 Dec 9 2020 'Colab Notebooks'
        -rw----- 1 root root 2388667849 Dec 4 16:43 features.csv.zip
       drwx----- 2 root root 4096 Jan 21 08:43 nn

drwx----- 2 root root 4096 Mar 27 08:53 PyTorch

-rw----- 1 root root 15020 Oct 29 2020 task_1.drawio

-rw----- 1 root root 1767 Oct 29 2020 'Untitled Diagram.drawio'

-rw----- 1 root root 143 Apr 2 2021 Резюме.gdoc
!ls /content/gdrive/"My Drive"/PyTorch/lesson3/data -la
        total 443208
        -rw----- 1 root root 4144048 Mar 27 08:34 sample_submission.csv.zip
        -rw----- 1 root root 116236318 Mar 28 08:46 test.csv.zip
        -rw----- 1 root root 333463334 Mar 28 08:48 train.csv.zip
Просматриваем подключенные диски
!df -h
        Filesystem Size Used Avail Use% Mounted on
        overlay
                            108G 40G 69G 37% /

        overlay
        108G
        40G
        69G
        37% /

        tmpfs
        64M
        0
        64M
        0% /dev

        shm
        5.8G
        0
        5.8G
        0% /dev/shm

        /dev/root
        2.0G
        1.2G
        817M
        59% /sbin/docker-init

        tmpfs
        6.4G
        32K
        6.4G
        1% /var/colab

        /dev/sda1
        81G
        44G
        38G
        54% /etc/hosts

        tmpfs
        6.4G
        0
        6.4G
        0% /proc/acpi

        tmpfs
        6.4G
        0
        6.4G
        0% /proc/scsi

        tmpfs
        6.4G
        0
        6.4G
        0% /sys/firmware

        drive
        15G
        3.3G
        12G
        22% /content/gdrive

! pwd
        /content
Просматриваем содержимое диска
!ls /content/gdrive/
        MyDrive
!ls /content/gdrive/"My Drive"/PyTorch/lesson3/data -la
       total 443208
        -rw----- 1 root root 4144048 Mar 27 08:34 sample_submission.csv.zip
        -rw----- 1 root root 116236318 Mar 28 08:46 test.csv.zip
        -rw----- 1 root root 333463334 Mar 28 08:48 train.csv.zip
Копирование данных с Google Drive на локальный диск виртуальной машины
# !cp /content/gdrive/'My Drive'/PyTorch/lesson3/data/*.* .
!cp /content/gdrive/'My Drive'/PyTorch/lesson3/data/train.csv.zip .
!ls -la
        total 325676
                                                 4096 Mar 30 08:55 .
        drwxr-xr-x 1 root root
        drwxr-xr-x 1 root root
                                                 4096 Mar 30 08:53 ..
        drwxr-xr-x 4 root root
                                                 4096 Mar 23 14:21 .config
        drwxr-xr-x 3 root root
                                                 4096 Mar 30 08:54 drive
                                                 4096 Mar 30 08:55 gdrive
        drwx----- 5 root root
        drwxr-xr-x 1 root root
                                                 4096 Mar 23 14:22 sample_data
        -rw----- 1 root root 333463334 Mar 30 08:55 train.csv.zip
!mv train.csv.zip /content/drive/my_drive/data/train.csv.zip
# !mv test.csv.zip /content/drive/my_drive/data/test.csv.zip
# !mv sample_submission.csv.zip /content/drive/my_drive/data/sample_submission.csv.zip
!ls -la
       total 24
        drwxr-xr-x 1 root root 4096 Mar 30 08:55 .
```

```
drwxr-xr-x 1 root root 4096 Mar 30 08:53 ..
drwxr-xr-x 4 root root 4096 Mar 23 14:21 .config
drwxr-xr-x 3 root root 4096 Mar 30 08:54 drive
drwx----- 5 root root 4096 Mar 30 08:55 gdrive
drwxr-xr-x 1 root root 4096 Mar 23 14:22 sample_data
```

Распаковка

→ Import libs

```
import os, sys
import numpy as np
import pandas as pd

import torch
from torch import nn
from torch import optim

import torchvision
import torchvision.transforms as transforms

from tqdm import tqdm # means "progress" in Arabic (taqadum)

# import matplotlib.pyplot as plt ### воспользуемся для отображения изображения
!pwd

/content
```

File and column descriptions

train.csv - Train data.

```
item_id - Ad id.
user_id - User id.
region - Ad region.
city - Ad city.
parent_category_name - Top level ad category as classified by Avito's ad model.
category_name - Fine grain ad category as classified by Avito's ad model.
param_1 - Optional parameter from Avito's ad model.
param_2 - Optional parameter from Avito's ad model.
param_3 - Optional parameter from Avito's ad model.
title - Ad title.
description - Ad description.
price - Ad price.
item_seq_number - Ad sequential number for user.
activation_date - Date ad was placed.
user_type - User type.
image - Id code of image. Ties to a jpg file in train_jpg. Not every ad has an image.
```

image_top_1 - Avito's classification code for the image.

deal_probability - The target variable.

This is the likelihood that an ad actually sold something. It's not possible to verify every transaction with certainty, so this column's value can be any float from zero to one.

→ 1 Data loading

```
PATH_DATA = '/content/drive/my_drive/data/'
```

▼ 1.1 Train data

```
data_train = pd.read_csv(PATH_DATA + "train.csv")
# train = pd.read_csv(PATH_DATA + "train.csv")
# data_train = train.head(3000)
data_train.info()
          <class 'pandas.core.frame.DataFrame'>
          RangeIndex: 1503424 entries, 0 to 1503423
          Data columns (total 18 columns):
                                     Non-Null Count
            # Column
                                                                                                      Dtype
           0 item_id 1503424 non-null object 1 user_id 1503424 non-null object 2 region 1503424 non-null object 3 city 1503424 non-null object
           ---
          4 parent_category_name 1503424 non-null object
5 category_name 1503424 non-null object
6 param_1 1441848 non-null object
7 param_2 848882 non-null object
8 param_3 640859 non-null object
9 title 1503424 non-null object
10 description 1387148 non-null object
11 price 1418062 non-null float64
12 item_seq_number 1503424 non-null int64
13 activation_date 1503424 non-null object
14 user_type 1503424 non-null object
15 image 1390836 non-null object
16 image_top_1 1390836 non-null float64
17 deal_probability 1503424 non-null float64
dtypes: float64(3), int64(1), object(14)
            4 parent_category_name 1503424 non-null object
          dtypes: float64(3), int64(1), object(14)
          memory usage: 206.5+ MB
data_train.head(3)
```

```
# data_train.dtypes
```

```
data_train['activation_date_int'] = pd.to_numeric(data_train['activation_date'].str.replace("-", "")).astype(int)
data_train['activation_date'] = pd.to_datetime(data_train.activation_date)
data_train['day_of_month'] = data_train.activation_date.apply(lambda x: x.day)
data_train['day_of_week'] = data_train.activation_date.apply(lambda x: x.weekday())
data_train['month'] = data_train.activation_date.apply(lambda x: x.month)
# data_train['month'] = data_train['activation_date'].dt.month

data_train[['activation_date', 'activation_date_int', 'day_of_month', 'day_of_week', 'month']].head()
```

```
group = data_train.groupby('region')['deal_probability']
# group.all()
group.count()
     region
                                 41520
     Алтайский край
                                 68291
     Башкортостан
     Белгородская область
                                 28868
     Владимирская область
                                 26741
                                 48998
     Волгоградская область
     Воронежская область
                                 44116
     Иркутская область
                                 44030
                                 32756
     Калининградская область
     Кемеровская область
                                 44635
                                141416
     Краснодарский край
                                 53442
     Красноярский край
     Нижегородская область
                                 73643
                                 62486
     Новосибирская область
     Омская область
                                 42939
                                 29303
     Оренбургская область
     Пермский край
                                 62704
                                 89995
     Ростовская область
     Самарская область
                                 73407
     Саратовская область
                                 49645
     Свердловская область
                                 94475
                                 39187
     Ставропольский край
                                 81284
     Татарстан
     Тульская область
                                 25733
```

35411

28537

28709

78339

32814

group.describe()

Удмуртия

Тюменская область

Ханты-Мансийский АО

Челябинская область

Ярославская область

Name: deal_probability, dtype: int64

```
from tqdm import notebook # IPython/Jupyter Notebook progressbar decorator for iterators.
cols = ['region', 'city', 'category_name', 'user_type']
for col in notebook.tqdm(cols):
    group = data_train.groupby(col)['deal_probability'] # deal_probability - вероятность сделки
    mean = group.mean()
    data_train[col + '__deal_probability_avg'] = data_train[col].map(mean) # convert the data to the desired format
data_train['_deal_probability'] = data_train['deal_probability']
data_train = data_train.drop([
'item_id',
'user_id',
'region',
'city',
'parent_category_name',
'category_name',
'param_1',
'param_2',
'param_3',
'title',
'description',
# 'price',
# 'item_seq_number',
'activation_date',
'user_type',
'image',
# 'image_top_1',
'deal_probability'
], axis=1)
cols
     ['region', 'city', 'category_name', 'user_type']
for col in data_train.columns:
    if data_train[col].isna().sum() > 0:
        data_train[col].fillna(data_train[col].median(), inplace=True)
# В итоге получаем
data_train.head(3)
```

• 1. Создать Dataset для загрузки данных (используем только числовые данные)

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
Чтобы изменить содержимое ячейки, дважды нажмите на нее (или выберите "Ввод")
# data_train = data_train.head(10000)
# разделим данные на train/test
# train-test разделение нужно сделать с помощью sklearn random_state=13, test_size = 0.25
X_train, X_test = train_test_split(data_train, test_size =0.25, random_state=13)
X_train.head(3)
idx=0
y_0 = X_train.iloc[idx, -1:]
print(y_0)
x_0 = X_{train.iloc[idx, 0:-1]}
print(x_0)
     _deal_probability
     Name: 31723, dtype: float64
     price
                                           1.300000e+03
                                           6.000000e+00
     item_seq_number
     image_top_1
                                           1.056000e+03
     activation_date_int
                                         2.017032e+07
     day_of_month
                                         2.300000e+01
     day_of_week
                                          3.000000e+00
     month
                                           3.000000e+00
                                   1.470655e-01
     region__deal_probability_avg
     city__deal_probability_avg
                                           1.890690e-01
     category_name__deal_probability_avg 1.784801e-01
                                           1.495572e-01
     user_type__deal_probability_avg
     Name: 31723, dtype: float64
from torch.utils.data import Dataset
class AvitoDataset(Dataset):
    def __init__(self, init_dataset, normalize=False, transform=None):
      self._base_dataset = init_dataset
      self.normalize = normalize
      self.transform = transform
    def __len__(self):
      return len(self._base_dataset)
    def __getitem__(self, idx):
      """ Основной метод-точка входа для наборов данных PyTorch
      Аргументы:
          idx (int): индекс данных
      Возвращает:
          словарь признаков (x_data) и метки (y_target) данных
      y = self._base_dataset.iloc[idx, -1:]
      # y = torch.tensor(y.values, dtype=torch.float)
      y = torch.FloatTensor(y.values)
      row = torch.FloatTensor(self._base_dataset.iloc[idx, 0:-1].values)
      return row, y
```

df_train, df_test = AvitoDataset(X_train), AvitoDataset(X_test)

- 2. Обернуть его в Dataloader

3. Написать архитектуру сети, которая предсказывает число показов на основании числовых данных (вы всегда можете нагенерить дополнительных факторов). Сеть должна включать BatchNorm слои и Dropout (или НЕ включать, но нужно обосновать)

```
# import torch.nn.functional as F
# class FeedForwardNN(nn.Module):
      def __init__(self, input_dim, hidden_dim):
          ''' B init() - делаем необходимые настройки.
#
#
          Аргументы:
            input_dim - размерность вектора входных данных
            hidden_dim - параметр для настройки скрытых слоёв
          super(FeedForwardNN, self).__init__()
#
          self.bn1 = nn.BatchNorm1d(input_dim)
          self.fc1 = nn.Linear(input_dim, 4*hidden_dim)
#
          self.dp1 = nn.Dropout(0.25)
#
          self.bn2 = nn.BatchNorm1d(4*hidden_dim)
          self.fc2 = nn.Linear(4*hidden_dim, 3*hidden_dim)
          self.dp2 = nn.Dropout(0.15)
#
          self.bn3 = nn.BatchNorm1d(3*hidden_dim)
          self.fc3 = nn.Linear(3*hidden_dim, 2*hidden_dim)
          self.dp3 = nn.Dropout(0.15)
          self.bn4 = nn.BatchNorm1d(2*hidden_dim)
          self.fc4 = nn.Linear(2*hidden_dim, 1)
      def forward(self, x):
          x = self.bn1(x)
          x = self.fc1(x)
          # Задаём функцию потерь Leaky_relu
          \# x = F.leaky_relu(x, 0.05)
          x = torch.tanh(x)
          x = self.dp1(x)
#
          x = self.bn2(x)
#
          x = self.fc2(x)
#
          # Задаём функцию потерь Leaky_relu
          \# x = F.leaky_relu(x, 0.05)
          x = torch.tanh(x)
#
          x = self.dp2(x)
#
          x = self.bn3(x)
          x = self.fc3(x)
#
          # Задаём функцию потерь Leaky_relu
#
          \# x = F.leaky_relu(x, 0.05)
          x = torch.tanh(x)
          x = self.dp3(x)
```

```
x = self.bn4(x)
#
          x = self.fc4(x)
          x = torch.sigmoid(x)
#
          return x
    # def predict(self, x):
          x = self.forward(x)
          x = F.softmax(x)
          return x
# net = FeedForwardNN(11, 4)
# print(net)
class FeedForwardNN(nn.Module):
    def __init__(self, input_dim, hidden_dim):
        super(FeedForwardNN, self).__init__()
        self.bn1 = nn.BatchNorm1d(input_dim)
        self.fc1 = nn.Linear(input_dim, 8*hidden_dim)
        self.dp1 = nn.Dropout(0.25)
        self.bn2 = nn.BatchNorm1d(8*hidden_dim)
        self.fc2 = nn.Linear(8*hidden_dim, 4*hidden_dim)
        self.dp2 = nn.Dropout(0.15)
        self.bn3 = nn.BatchNorm1d(4*hidden_dim)
        self.fc3 = nn.Linear(4*hidden_dim, 2*hidden_dim)
        self.dp3 = nn.Dropout(0.15)
        self.bn4 = nn.BatchNorm1d(2*hidden_dim)
        self.fc4 = nn.Linear(2*hidden_dim, 1)
    def forward(self, x):
       x = self.bn1(x)
        x = self.fc1(x)
        x = torch.tanh(x)
        x = self.dp1(x)
        x = self.bn2(x)
        x = self.fc2(x)
        x = torch.tanh(x)
        x = self.dp2(x)
        x = self.bn3(x)
        x = self.fc3(x)
        x = torch.tanh(x)
        x = self.dp3(x)
        x = self.bn4(x)
        x = self.fc4(x)
        x = torch.sigmoid(x)
        return x
```

- 4. Учить будем на функцию потерь с кагла (log RMSE) - нужно её реализовать

$$RMSLE = \sqrt{rac{1}{n}\sum_{i=1}^n (\log y_i - \log \hat{y_i})^2},$$

```
# d_i = (K.log(y_pred) - K.log(y_true))
# loss1 = K.mean(K.square(d_i))
# loss2 = K.square(K.sum(K.flatten(d_i),axis=-1))/(K.cast_to_floatx(2) * K.square(K.cast_to_floatx(K.int_shape(K.flatten(d_i))[0])
# loss = loss1 - loss2
# return loss
```

5. Сравните сходимость (Оптимизаторы) Adam, RMSProp и SGD, сделайте вывод по качеству работы модели

train-test разделение нужно сделать с помощью sklearn random_state=13, test_size = 0.25

```
epochs = 5
lr = 0.01
for batch, label in train_loader:
    print(batch.shape)
    break
     torch.Size([1024, 11])
def tr_loss(test_loader, model):
    batches = len(test_loader)
    loss = 0
    with torch.no_grad():
        for X, y in test_loader:
            y_pred = model(X)
            loss += log_rmse(y_pred, y)
   loss /= batches
    return loss
def train_proc(train_loader, test_loader, model, optimizer):
    for i, data in enumerate(train_loader):
        inputs, labels = data[0], data[1]
        y_pred = model(inputs)
        loss = log_rmse(y_pred, labels)
        # обнуляем градиент
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
    return tr_loss(test_loader, model)
```

→ ADAM

```
model = FeedForwardNN(11, 8)
print(model)
     FeedForwardNN(
       (bn1): BatchNorm1d(11, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
       (fc1): Linear(in_features=11, out_features=64, bias=True)
       (dp1): Dropout(p=0.25, inplace=False)
       (bn2): BatchNorm1d(64, eps=1e-05, momentum=0.1, affine=True, track running stats=True)
       (fc2): Linear(in_features=64, out_features=32, bias=True)
       (dp2): Dropout(p=0.15, inplace=False)
       (bn3): BatchNorm1d(32, eps=1e-05, momentum=0.1, affine=True, track running stats=True)
       (fc3): Linear(in_features=32, out_features=16, bias=True)
       (dp3): Dropout(p=0.15, inplace=False)
       (bn4): BatchNorm1d(16, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
       (fc4): Linear(in_features=16, out_features=1, bias=True)
optimizer = torch.optim.RMSprop(model.parameters(), lr=lr)
print(f'ADAM:\n')
for epoch in tqdm(range(epochs)):
    result = train_proc(train_loader,
```

```
test_loader,
                         model,
                         optimizer
                         )
print(f'Test_loss={result}')
 ADAM:
  20%
                | 1/5 [11:24<45:36, 684.04s/it]Test_loss=0.18010510504245758
  40%
                  2/5 [22:52<34:20, 686.85s/it]Test_loss=0.1796482801437378
  60%
                  3/5 [34:31<23:04, 692.17s/it]Test_loss=0.1796303391456604
  80%
                  4/5 [46:23<11:40, 700.17s/it]Test_loss=0.17977136373519897
 100%
                 | 5/5 [58:27<00:00, 701.51s/it]Test_loss=0.18032890558242798
```

→ RMSProp

```
model = FeedForwardNN(11, 8)
optimizer = torch.optim.Adam(model.parameters(), lr=lr)
print(f'RMSprop:\n')
for epoch in tqdm(range(epochs)):
    result = train_proc(train_loader,
                             test_loader,
                             model,
                             optimizer
    print(f'Test_loss={result}')
     RMSprop:
      20%
                     | 1/5 [11:52<47:28, 712.18s/it]Test_loss=0.1798865646123886
      40%
                      2/5 [23:56<35:58, 719.39s/it]Test_loss=0.17945596575737
      60%
                      3/5 [35:57<24:00, 720.25s/it]Test_loss=0.17960643768310547
      80%
                     4/5 [47:46<11:55, 715.83s/it]Test_loss=0.17945215106010437
                     | 5/5 [59:31<00:00, 714.30s/it]Test_loss=0.17936037480831146
     100%
```

▼ SGD

```
model = FeedForwardNN(11, 8)
optimizer = torch.optim.SGD(model.parameters(), lr=lr)
print(f'SGD:\n')
for epoch in tqdm(range(epochs)):
    result = train_proc(train_loader,
                             test_loader,
                             model,
                             optimizer
    print(f'Test_loss: {result}')
     SGD:
                    | 1/5 [11:40<46:42, 700.52s/it]Test_loss: 0.19872649013996124
      20%
      40%
                    2/5 [23:29<35:16, 705.33s/it]Test_loss: 0.18643750250339508
                      3/5 [35:04<23:21, 700.80s/it]Test_loss: 0.1849292516708374
                      4/5 [46:41<11:39, 699.26s/it]Test_loss: 0.18434157967567444
      80%
                    | 5/5 [58:12<00:00, 698.50s/it]Test loss: 0.1837015599012375
```

▼ Вывод:

Наилучшую сходимость и лучший результат наблюдаем при использовании оптимизатора RMSProp

```
# for epoch in tqdm(range(epochs)):
# running_loss = 0.0
# for i, data in enumerate(train_loader):
# inputs, labels = data[0], data[1]
# # обнуляем градиент
# optimizer.zero_grad()
```

```
# outputs = model(inputs)
# loss = log_rmse(outputs, labels)
# loss.backward()
# optimizer.step()

# # BыВодим статистику о процессе обучения
# running_loss += loss.item()
# if i % 300 == 0: # печатаем каждые 300 mini-batches
# print('[%d, %5d] loss: %.3f' %
# (epoch + 1, i + 1, running_loss / 300))
# running_loss = 0.0

# print('Training is finished!')
```

Root Mean Squared Error (RMSE) Submissions are scored on the root mean squared error. RMSE is defined as:

$$RMSE = \sqrt{rac{1}{n}\sum_{i=1}^n (y_i - \hat{y_i})^2},$$

where y hat is the predicted value and y is the original value.

